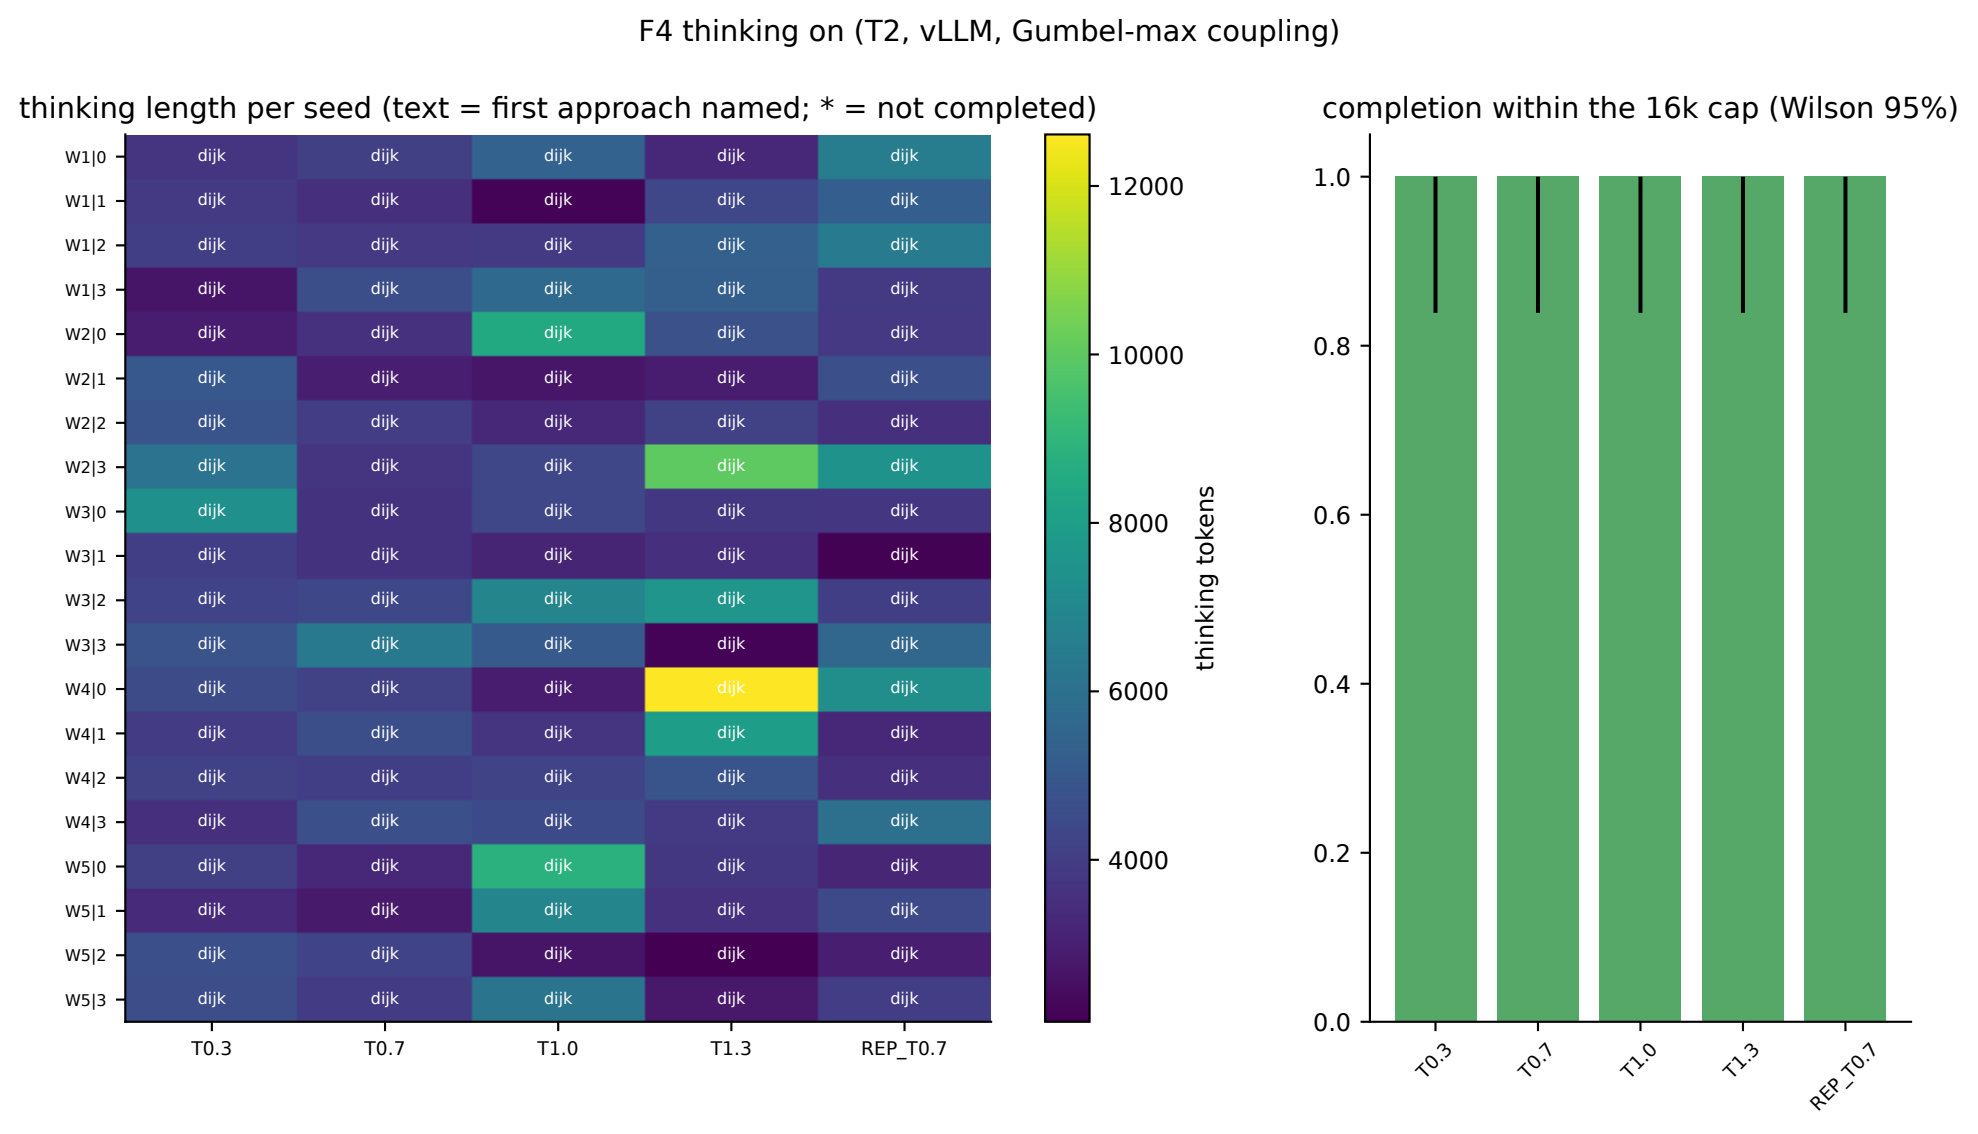
F4 thinking on (T2, vLLM, Gumbel-max coupling)
thinking length per seed (text = first approach named; * = not completed)
W1|0 dijk dijk dijk dijk dijk
W1|1 dijk dijk dijk dijk dijk
W1|2 dijk dijk dijk dijk dijk
W1|3 dijk dijk dijk dijk dijk
W2|0 dijk dijk dijk dijk dijk
W2|1 dijk dijk dijk dijk dijk
W2|2 dijk dijk dijk dijk dijk
W2|3 dijk dijk dijk dijk dijk
W3|0 dijk dijk dijk dijk dijk
W3|1 dijk dijk dijk dijk dijk
W3|2 dijk dijk dijk dijk dijk
W3|3 dijk dijk dijk dijk dijk
W4|0 dijk dijk dijk dijk dijk
W4|1 dijk dijk dijk dijk dijk
W4|2 dijk dijk dijk dijk dijk
W4|3 dijk dijk dijk dijk dijk
W5|0 dijk dijk dijk dijk dijk
W5|1 dijk dijk dijk dijk dijk
W5|2 dijk dijk dijk dijk dijk
W5|3 dijk dijk dijk dijk dijk
T0.3
T0.7
T1.0
T1.3
REP_T0.7
12000
10000
8000
6000
4000
thinking tokens
completion within the 16k cap (Wilson 95%)
1.0
0.8
0.6
0.4
0.2
0.0
T0.3
T0.7
T1.0
T1.3
REP_T0.7